


20% TRAIN


Este modelo dispone de mucha menos información para aprender patrones generales en lugar de casos aislados o ruido, por lo que se debe trabajar con arquitecturas más simples.

1 CAPA CON 2 NEURONAS


Se podría considerar que es un mínimo para que se empiecen a ver resultados, aunque la mayoría son malos y nada confiables, por ejemplo el **TANH** se empieza a acercar a una división correcta




RELU




SIGMOID



TANH




LINEAR




3 CAPAS CON 2-3 NEURONAS

La mayor importancia en este modelo es la activación de la neurona X_1X_2 , la cual subdivide el espacio de división en dos cuadrantes opuestos. Gracias a esto el algoritmo “aprende” que no tiene por que ser una única línea fornteriza.




3 CAPAS CON 2-4 NEURONAS


A diferencia del apartado anterior, vamos a ver cuánto necesitaremos sin incluir la neurona X_1X_2 para ver si el algoritmo es capaz de detectar la frontera(s) sin ella.



RELU




TANH



80% TRAIN


En este caso el modelo es mucho más preciso y tiene mejor reacción a mayores capas y ajuste.

3 CAPAS CON 6-7 NEURONAS




Como hemos dicho, una mejor reacción al ajuste gracias al mayor entrenamiento.

Activation Sigmoid




Al igual que en el caso anterior, RELU y TANH son los que mejor funcionan gracias a como toman las fronteras de decisión.

1 CAPA CON 7 NEURONAS




Activation Tanh



Realmente no se aprecia una bajada drástica en los patrones al disminuir las capas, simplemente se puede apreciar que tienden más a fronteras o separaciones no lógicas o fundamentadas en nada (a falta de mejora de una capa a otra y poder pulir el OUTPUT)

Otros ajustes



Regularization

- Ayuda a **evitar el sobreajuste**, sobre todo si usas muchas capas o neuronas.
- En Playground, L2 regularization suaviza la frontera de decisión y evita que el modelo se adapte demasiado al ruido.
- Con **80% de datos**, la regularización empieza a tener más impacto.

Learning Rate

- Es clave para que el modelo aprenda bien.
- Si es muy bajo, el modelo tarda mucho en converger o se queda atascado.
- Si es muy alto, el modelo salta la solución óptima y genera ruido.
- En XOR, un valor moderado (0.03–0.07) suele ser ideal, especialmente si usas activaciones como tanh o ReLU.

